Relatório: Distribuição Normal e Curva de Gauss

Análise Estatística da Base *Students Performance in Exams*

Probabilidade e Estatística Aplicada

Outubro de 2026

Parte A — Pesquisa Teórica

1. Conceito de Distribuição Normal: A distribuição normal (ou distribuição gaussiana) é uma distribuição de probabilidade contínua fundamental na estatística. Ela modela fenômenos nos quais a maioria das observações se concentra em torno de um valor central, enquanto valores extremos ocorrem com frequência progressivamente menor à medida que se afastam do centro.

2. Características da Curva de Gauss: O gráfico da função densidade de probabilidade da distribuição normal é chamado de **Curva de Gauss** e possui as seguintes propriedades:

- **Formato de sino e unimodalidade:** possui um único pico central onde a densidade é máxima;
- **Simetria perfeita:** a curva é simétrica em relação ao centro, onde média, mediana e moda coincidem (μ = mediana = moda);
- **Assintótica:** suas extremidades aproximam-se do eixo horizontal sem nunca tocá-lo;
- **Área total igual a 1:** a integral sob toda a curva corresponde a 100% da probabilidade.

A função densidade da distribuição normal é dada por:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

3. Função da Média (μ ou $\bar{x}$): É o parâmetro de posição (localização) que determina o centro de gravidade e o eixo de simetria da distribuição. Mudanças na média deslocam a curva horizontalmente sem alterar sua forma.

4. Função do Desvio-Padrão (σ ou s): É o parâmetro de dispersão (escala) que mede o espalhamento dos dados ao redor da média. Valores menores de σ produzem curvas estreitas e altas (dados concentrados), enquanto valores maiores produzem curvas largas e achatadas (dados dispersos). Para uma amostra de tamanho n, utiliza-se:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

5. Significado da Regra 68–95–99,7: Em distribuições aproximadamente normais, espera-se que:

- $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 68\%$ dos dados estejam a até 1 desvio-padrão da média;
- $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 95\%$ estejam a até 2 desvios-padrão da média;
- $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 99,7\%$ estejam a até 3 desvios-padrão da média.

6. Conceito de Escore Padronizado z: O escore z mede quantos desvios-padrão uma observação x está distante da média amostral $\bar{x}$:

$$z = \frac{x - \bar{x}}{s}$$

Valores com $|z| > 3$ encontram-se na região extrema das caudas (menos de $0,3\%$ de probabilidade na curva normal) e são classificados como possíveis valores atípicos (*outliers*).

Parte B — Leitura e Organização dos Dados

O arquivo `StudentsPerformance.csv` foi lido em Python utilizando `csv.DictReader` e convertendo a coluna `math score` para números inteiros:

- **Registros carregados:** 1.000 registros válidos.
- **Valores ausentes ou inválidos:** 0 registros.

Parte C — Medidas Estatísticas (`math score`)

Os cálculos foram efetuados diretamente em Python sem uso de bibliotecas estatísticas:

Medida Estatística	**Resultado**	**Medida Estatística**	**Resultado**
1. Quantidade de dados (n)	1.000	6. Mediana	$66,00$
2. Menor nota	0	7. Moda	65 (36 ocorrências)
3. Maior nota	100	8. Variância amostral (s^2)	$229,9190$
4. Amplitude total	100	9. Desvio-padrão amostral (s)	$15,1631$
5. Média aritmética ($\bar{x}$)	$66,0890$	10. Coeficiente de assimetria	$-0,2789$

Parte D — Regra 68–95–99,7

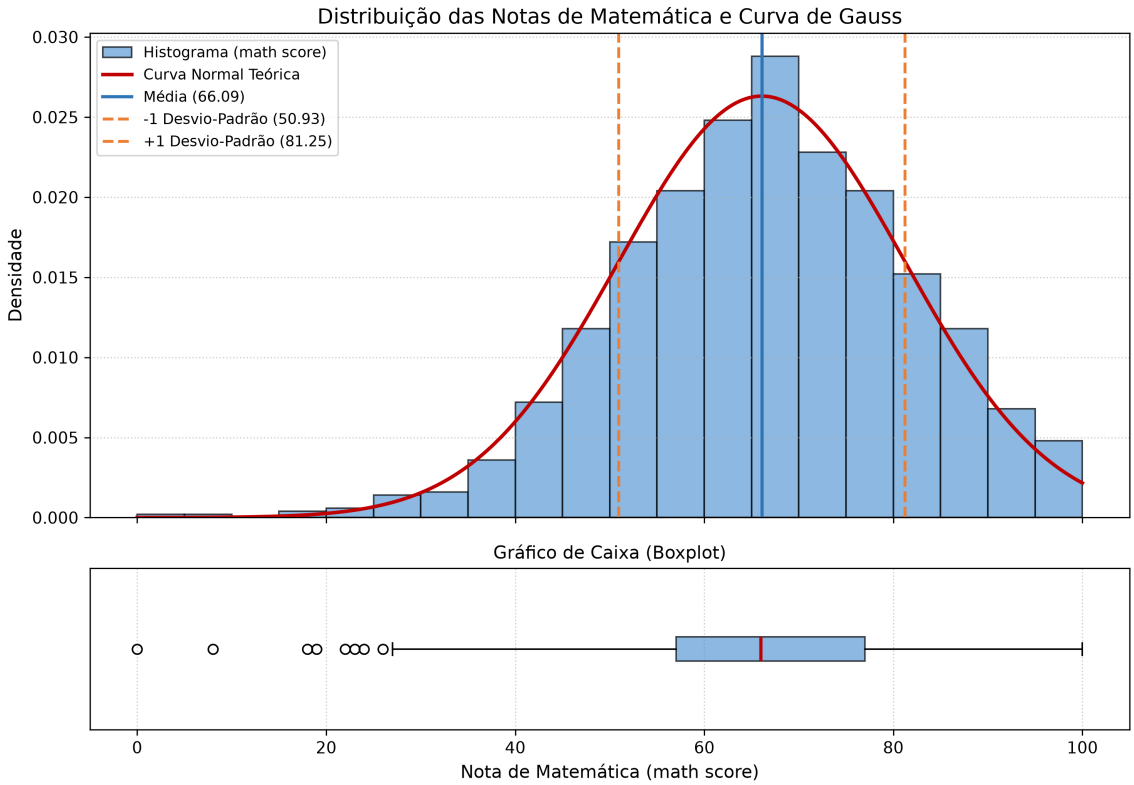
Intervalo	**Limites**	**Quantidade**	**Percentual Observado**	**Teórico**
Entre $\bar{x} - s$ e $\bar{x} + s$	$[50,93;\ 81,25]$	696	$69,60\%$	$\approx 68,0\%$
Entre $\bar{x} - 2s$ e $\bar{x} + 2s$	$[35,76;\ 96,42]$	954	$95,40\%$	$\approx 95,0\%$
Entre $\bar{x} - 3s$ e $\bar{x} + 3s$	$[20,60;\ 111,58]$	996	$99,60\%$	$\approx 99,7\%$

Parte E — Escores Padronizados (z) e Valores Atípicos

Caso Analisado	**Nota (x)**	**Escore z**	**Classificação ($\lvert z\rvert > 3$)**
Menor nota	0	$-4,3585$	**Atípico** ($\lvert z\rvert > 3$)
Maior nota	100	$+2,2364$	Normal ($\lvert z\rvert \leq 3$)
Nota igual a 50	50	$-1,0611$	Normal ($\lvert z\rvert \leq 3$)
Nota igual a 75	75	$+0,5877$	Normal ($\lvert z\rvert \leq 3$)
Nota igual a 90	90	$+1,5769$	Normal ($\lvert z\rvert \leq 3$)

Em toda a base de dados, existem exatamente **4 notas atípicas** ($|z| > 3$), todas na cauda inferior: $x = 0$ ($z = -4,3585$), $x = 8$ ($z = -3,8309$), $x = 18$ ($z = -3,1715$) e $x = 19$ ($z = -3,1055$).

Parte F — Representação Gráfica



Parte G — Conclusão

1. **O histograma apresenta aproximadamente o formato de sino?** Sim. Há nítida concentração central em torno de 66 pontos e queda gradual das frequências para ambos os lados, acompanhando o contorno da Curva de Gauss.

2. **Média e mediana apresentam valores próximos?** Sim, são praticamente iguais: média $\bar{x} = 66,09$ e mediana $= 66,00$ (além da moda $= 65$).

3. **Os percentuais observados são próximos da regra 68–95–99,7?** Sim. Os percentuais empíricos ($69,60\%$, $95,40\%$ e $99,60\%$) são extremamente próximos aos valores teóricos (68%, 95% e $99,7\%$).

4. **A distribuição apresenta assimetria?** Apresenta uma leve assimetria negativa (assimetria $= -0,2789$), pois a cauda esquerda se prolonga até a nota 0, enquanto a direita é limitada pela nota máxima 100.

5. **Existem valores atípicos?** Sim, quatro notas na extremidade inferior ($0, 8, 18$ e 19) possuem $|z| > 3$, também destacadas no *boxplot*.

6. **É adequado afirmar que os dados seguem perfeitamente uma distribuição normal?** Não. As notas são discretas e limitadas ao intervalo $[0, 100]$, apresentando leve assimetria à esquerda e truncamento no limite superior.

7. **Qual seria uma conclusão mais cuidadosa sobre a distribuição das notas?** As notas de matemática não seguem uma distribuição normal exata, mas apresentam comportamento **aproximadamente normal**, tornando a Curva de Gauss um excelente modelo prático para descrever o desempenho dos estudantes, ressalvando-se apenas a presença de 4 notas atípicas inferiores e o teto natural de 100 pontos.